


Prompt Mühendisliği Ustalık Sınıfı

Temellerden Otonom Agent'lara: Yapay Zeka ile Diyalog Sanatı



Ustalığın Yol Haritası: Araç Setimiz

Bu sunum, prompt mühendisliği tekniklerini bir katalog gibi değil, belirli sorunları çözmek için tasarlanmış stratejik bir araç seti olarak ele alır. Temel el aletlerinden başlayıp, geleceğin otonom sistemlerine uzanan bir yolculuğa çıkacağız.



Giriş ve Temel Araçlar

Her projenin başlangıcı.



Karmaşık Akıl Yürütme

Hassasiyet ve derinlik gerektiren görevler için.



Modelin Bilgisinin Ötesi

Atölyeyi dış dünyaya bağlamak.



Prompt Otomasyonu

Araçları kendi kendine iyileştiren sistemler.



İleri Düzey ve Mimariler

Geleceği şekillendiren teknikler.

Temel Araçlar: Zero-Shot & Few-Shot Prompting



Zero-Shot Prompting (Sıfır Örnekli)

Modele hiçbir örnek veya demonstrasyon sunmadan, doğrudan bir görev talimatı vermektir. Modelin geniş eğitim verisinden öğrendiği 'talimat takip etme' yeteneğine dayanır.

```
Prompt: `Metni nötr, negatif veya pozitif olarak sınıflandır.
Metin: Bence tatil fena değildi. Duygu:`
\n
Çıktı: `Nötr`
```

****Ne Zaman Kullanılır?**: Basit, tek adımlı görevler ve modelin görevi zaten anladığı durumlar için idealdir.**



Few-Shot Prompting (Az Örnekli)

Modelin performansını yönlendirmek için prompt içinde demonstrasyonlar (örnekler) sunarak bağlam içi öğrenmeyi (in-context learning) sağlamaktır. Model, verilen örneklerden görevin formatını ve mantığını öğrenir.

```
Prompt: `Bir "whatpu", Tanzania'ya özgü küçük, tüylü bir hayvandır. Whatpu kelimesini kullanan bir cümle örneği: Afrika'da seyahat ederken bu çok sevimli whatpu'ları gördük. "Farduddle" yapmak, çok hızlı bir şekilde yukarı aşağı zıplamak demektir. Farduddle kelimesini kullanan bir cümle örneği:` \n
Çıktı: `Oyunu kazandığımızda hepimiz kutlama yapmak için farduddle yapmaya başladık.`
```

****Ne Zaman Kullanılır?**: Modelin istenen çıktı formatını veya görev mantığını anlaması için birkaç örneğe ihtiyaç duyduğu durumlarda kullanılır.**

Akıl Yürütmeyi Ortaya Çıkarmak: Düşünce Zinciri (Chain-of-Thought)

LLM'lerden sadece nihai cevabı değil, cevaba giden 'düşünce adımlarını' da istemek. Bu, karmaşık problemlerde doğruluğu önemli ölçüde artırır ve modelin akıl yürütme sürecini şeffaf hale getirir.

Problem

Bu gruptaki tek sayılar çift bir sayıya toplanır: 15, 32, 5, 13, 82, 7, 1.

Standart Prompt Çıktısı

Yanlış Cevap ✗

CoT Prompt Çıktısı

Tüm tek sayıları toplamak (15, 5, 13, 7, 1) 41 eder. Cevap Yanlış'tır. ✓

Standart Yaklaşım



Düşünce Zinciri (CoT) Yaklaşımı




Varyasyonlar

- **Zero-Shot CoT:** Modele sadece "Adım adım düşünelim." ekleyerek akıl yürütme sürecini tetiklemek.
- **Automatic CoT (Auto-CoT):** Elle örnek hazırlamak yerine, LLM'lerin kendi akıl yürütme zincirlerini oluşturduğu ve soru kümeleme ile örnek çeşitliliğini artırdığı bir yaklaşımdır.

Güvenilirliği Artırmak: Öz-Tutarlılık (Self-Consistency)

Ana Fikir


Aynı soru için, az örnekli CoT (few-shot CoT) kullanarak birden fazla, çeşitli akıl yürütme yolu oluşturmak ve ardından bu yolların ürettiği sonuçlar arasında 'çoğunluk oylaması' yaparak en tutarlı cevabı seçmek. Bu yöntem, CoT'nin performansını özellikle aritmetik ve sağduyu gerektiren görevlerde daha da ileri taşır.



Bilgi Ufuklarını Geniřletme: Eriřim Artırımı Üretim (RAG)

Problem: LLM'ler, eğitim verilerinin kesildiđi tarihe kadar olan bilgiyle sınırlıdır. Güncel olaylar, özel řirket belgeleri veya niř alanlardaki bilgiler hakkında "halüsinasyon" "halüsinasyon" görebilirler veya bilgi eksikliđi yařayabilirler.

Çözüm: RAG: RAG, bu sorunu çözmek için bir bilgi erişim (retrieval) bileřenini bir metin üretme (generation) modeliyle birleřtirir. Modele cevap vermeden önce, harici ve güncel bir bilgi kaynađından ilgili belgeleri bulup getirmesini sađlar.




Faydaları: Gerçeklere daha uygun, güvenilir ve halüsinasyonu azaltılmıř çıktıları üretir. Modelin bilgisini yeniden eğitimden güncelleme imkanı sunar.

Akıllı Alet Kutusu: Harici Araç Kullanımı (PAL, ReAct, ART)

Temel Fikir

LLM'lerin sadece metin üretmekle kalmayıp, karmaşık hesaplamalar yapmak, güncel bilgiyi aramak veya kod çalıştırmak gibi görevler için dış dünyadaki araçları aktif olarak kullanmasını sağlamak.



1. PAL (Program-Aided Language Models)

Ne Yapar?: Doğal dildeki bir problemi anlar ve çözüm için metin yerine bir program (örn. Python kodu) üretir. Çözüm, bu kodun bir yorumlayıcı tarafından çalıştırılmasıyla elde edilir. Akıl yürütme adımlarını koda döker.

Güçlü Yönü: Matematik ve sembolik mantık gibi hassas ve kesin hesaplama gerektiren görevlerde çok etkilidir.

2. ReAct (Reason + Act)

Ne Yapar?: Düşünce (Reason) ve Eylem (Act) adımlarını bir döngü içinde birleştirir. LLM, bir sonraki eylemini planlamak için bir 'düşünce' üretir, ardından bu düşünceye dayalı bir 'eylem' (örn. `Search[konu]`) gerçekleştirir ve dış araçtan gelen 'gözlemi' (observation) alarak bir sonraki düşünce-eylem döngüsünü başlatır.

Güçlü Yönü: Dinamik ve çok adımlı görevlerde, bilgi toplama ve planlama yapma yeteneği sağlar.

3. ART (Automatic Reasoning and Tool-use)


Ne Yapar?: ReAct ve PAL'ın bir adım ötesine geçerek, yeni bir görev için hangi araçların ne zaman kullanılacağını bir görev kütüphanesinden otomatik olarak öğrenir. Üretim sırasında bir araç gerektiğinde duraklar, aracı kullanır ve çıktısını entegre ederek devam eder.

Güçlü Yönü: Araç kullanım sürecini insan müdahalesi olmadan otomatize eder ve genelleştirir.

Prompt'u Optimize Etmek: Otomatik Prompt Mühendisi (APE)

Ana Fikir

En iyi prompt'u bulma görevini, bir doğal dil sentezi problemi olarak ele almak. APE, LLM'leri kullanarak bir görev için en yüksek performansı sağlayacak talimatları (prompt'ları) otomatik olarak üretir ve seçer.



Çarpıcı Sonuç: APE, insan tarafından tasarlanan ünlü 'Let's think step by step' prompt'undan daha iyi performans gösteren '**Let's work this out in a step by step way to be sure we have the right answer**' gibi prompt'ları keşfetmiştir.

Dinamik Yönlendirme: Active-Prompt & Yönlü Uyarı

1. Active-Prompt (Aktif Prompt)

Problem: CoT gibi tekniklerde kullanılan sabit, insan tarafından seçilmiş örnekler (exemplars) her görev için en etkili olmayabilir.

Çözüm: Active-Prompt, en ‘belirsiz’ ve dolayısıyla en öğretici olan soruları akıllıca seçerek, bu soruları insanlar tarafından etiketlenmesi için sunar. Bu yeni ve değerli örnekler, prompt’a eklenerek modelin zorlandığı alanlarda performansını artırır.



2. Directional Stimulus Prompting (Yönlü Uyarı)

Fikir: Büyük ve “kara kutu” bir LLM’i doğrudan yönlendirmek yerine, daha küçük ve eğitilebilir bir “politika modeli” (policy LM) kullanmak.


Çalışma Prensipleri: Bu küçük politika modeli, büyük LLM’in istenen çıktıyı üretmesine yardımcı olacak ince ipuçları veya ‘uyaranlar’ (stimulus/hints) üretir. Bu uyarılar, ana prompt’a eklenerek büyük modeli doğru yöne ‘dürtükler’.



Hatalardan Öğrenme: Refleksiyon (Reflexion)

Ana Fikir

Reflexion, dil tabanlı agent'ları (agents) sözel geri bildirim (linguistic feedback) yoluyla güçlendiren bir çerçevedir. Agent'ın önceki denemelerindeki başarısızlıkları, bir 'öz-eleştiri' veya 'refleksiyon' metnine dönüştürülür ve bu metin, bir sonraki denemede agent'a bağlam olarak verilir.



- **Sonuç**
Agent, deneme yanılma yoluyla hızla öğrenir ve her denemede daha iyi kararlırlar alır. Bu, modelin **ince ayar (fine-tuning)** gerektirmeden davranışını iyileştirmesini sağlar.
- **Kullanım Alanları**: Sıralı karar verme (AlfWorld), akıl yürütme (HotPotQA) ve programlama (HumanEval) gibi görevlerde performansı önemli ölçüde artırır.

Ufuk Çizgisindeki Teknikler: Meta, Multimodal ve Graph Prompting



1. Meta Prompting

Odak: İçerikten ziyade, problemin yapısına (structure) ve sözdizimine (syntax) odaklanır. LLM'e bir görevin nasıl çözüleceğine dair spesifik örnekler yerine, çözümün genel şablonunu veya soyut yapısını verir.

Avantajı: Özellikle matematik ve kodlama gibi yapısal alanlarda, daha az token kullanarak daha genelleştirilebilir bir yönlendirme sağlar.



2. Multimodal CoT

Odak: Düşünce Zinciri (CoT) tekniğini metnin ötesine taşıyarak, metin ve görselleri birlikte içeren problemlerde akıl yürütme yeteneği kazandırır.

Süreç: İki aşamalıdır: İlk olarak, mantıksal bir gerekçe üretilir. İkinci olarak, bu gerekçe kullanılarak nihai cevap verilir.



3. Graph Prompting

Odak: Bilgiyi ve ilişkilerini düz metin yerine bir graf yapısı (nodes ve edges) olarak temsil ederek LLM'e sunar. Bu, LLM'nin veriler arasındaki karmaşık ilişkileri daha iyi anlamasını sağlar.

Kullanım: Özellikle bilgi grafları (knowledge graphs) veya sosyal ağ analizi gibi alanlarda potansiyel taşır.

Mimari Bir Desen: Prompt Zincirleme (Prompt Chaining)

Ana Fikir

Büyük ve karmaşık bir görevi, her biri bir öncekinin çıktısını girdi olarak kullanan daha küçük, yönetilebilir ve tek bir amaca odaklanmış prompt'lar serisine bölmektir.



Neden Önemli?

- **Güvenilirlik:** Her adımın çıktısını kontrol etmek ve doğrulamak daha kolaydır.
- **Hata Ayıklama (Debugging):** Zincirin hangi halkasında sorun yaşandığını tespit etmek basitleşir.
- **Kontrol Edilebilirlik:** Her bir prompt'un sorumluluğu net olduğu için süreci yönlendirmek daha kolaydır.
- **Şeffaflık:** LLM'in bir görevi nasıl tamamladığı adım adım izlenebilir.

Prompt Mühendisliği Ustalık Araç Seti: Tam Ekipman



Bilimden Sanata: Geleceğin Diyalogunu Tasarlamak

Prompt mühendisliği, sadece doğru soruları sormak değil; yapay zekanın düşünme, akıl yürütme ve problem çözme süreçlerini tasarlamaktır. LLM'lerin ham potansiyelini, ölçülebilir sonuçlara dönüştüren stratejik bir disiplindir.

Bu araç setindeki her teknik, bir bilimsel prensibe dayanır. Ancak bu araçları ne zaman, nasıl ve hangi kombinasyonla kullanacağınıza karar vermek, bir sanattır. Yapay zeka ile kurduğumuz diyalogun kalitesi, geleceği ne kadar etkili şekillendireceğimizi belirleyecektir.

